第44卷 第21期 2020年11月10日
DOI：10.7500/AEPS20200202004
电力系统自动化
Automation of Electric Power Systems
Vol. 44 No. 21 Nov. 10，2020

# 不确定性环境下数据驱动的电力系统优化调度方法综述

鲁卓欣[1]，徐潇源[1]，严　正[1]，吴　江[2]，桑　妲[2]，王　澍[2]
（1.电力传输与功率变换控制教育部重点实验室（上海交通大学），上海市 200240；
2.国家电网有限公司华东分部，上海市 200120）

**摘要：**随着可再生能源大规模并网，电力系统运行的不确定性显著增加，考虑不确定性因素的调度方法逐渐得到重视。另一方面，建立准确的不确定性因素模型是求解优化问题的前提与关键，可再生能源出力具有复杂的不确定性，其发电数据为随机调度提供了科学的数据支撑。文中总结了不确定性环境下数据驱动的电力系统调度的理论方法以及应用场景。首先，总结了传统随机优化调度中数据驱动的随机变量建模方法。其次，介绍了鲁棒优化调度中数据驱动的不确定性集合建模方法。然后，针对随机优化中不确定性因素建模不准确以及鲁棒优化结果较为保守的问题，重点阐述了基于数据驱动分布鲁棒的电力系统优化调度理论与方法，梳理了随机变量的概率分布模糊集构建方法和分布鲁棒优化的模型构建及求解算法。最后，对数据驱动的电力系统调度未来的研究工作进行了展望。

**关键词：**电力系统；数据驱动；随机优化；鲁棒优化；分布鲁棒优化；可再生能源

## 0　引言

化石燃料的使用产生大量温室气体，导致全球气温持续上升，生态环境遭到严重破坏。风能、太阳能等清洁能源的快速发展，为全球能源结构调整和应对气候变化奠定了基础。2010年以来，全球范围内可再生能源装机容量以平均每年8%的速度增长。预期到2050年，可再生能源约占全球总能源使用量的2/3[1]。《中国2050高比例可再生能源发展情景暨路径研究》[2]提出了到2050年建立以可再生能源为主的能源体系，可再生能源发电量占总发电量85%以上的发展目标。

电力系统调度是保证系统安全高效运行的基础，主要包含中长期、短期和实时调度。中长期或者短期调度通常以优化周期内的运行经济性与安全性为目标；而实时调度根据电力系统实时运行状态调整系统运行方式。随着可再生能源接入比例的不断提高，电力系统调度中的不确定性因素显著增加。相比于负荷，可再生能源发电具有更强的波动性与随机性，其大规模接入对电力系统安全可靠运行提出了挑战，因此考虑不确定性因素的决策方法在电力系统及综合能源系统调度中逐步得到了重视与应用。当前，随机优化和鲁棒优化是2种最为常用的电力系统不确定性管理方法。在随机优化中，通常需要设定随机变量的概率分布，但是假定的概率分布模型无法准确刻画实际不确定性因素的复杂变化规律[3]。鲁棒优化采用不确定性集合描述不确定性因素的变化范围，虽然不需要设定随机变量的概率分布，但是由于考虑最差场景下的最优解，可能会使得调度结果较为保守[4]。

近年来，随着电网量测系统的完善以及可再生能源的发展，积累了海量的可再生能源发电数据。对此，出现了较多数据驱动的优化调度方法，以克服传统随机优化与鲁棒优化在实际应用中的不足。这些数据驱动的优化调度方法可以分为2类：①基于可再生能源发电历史或预测数据建立随机变量模型，以提高调度方案在实际系统运行中的适用性；②挖掘数据所表征的统计信息，研究数据驱动的分布鲁棒优化（distributionally robust optimization，DRO），以解决传统随机优化中不确定性因素建模不准确的难题，并降低传统鲁棒优化的保守性。

考虑到电力系统运行中不确定性因素的不断增多以及数据驱动优化方法在电力系统中应用的日益广泛，有必要综述其在电力系统调度中的应用现状。需要说明的是，已有一些关于电力系统随机优化调度的综述文献[5-7]，但是这些综述主要总结传统随机优化或者鲁棒优化的应用，探讨基于参数概率

收稿日期：2020-02-02；修回日期：2020-06-17。
上网日期：2020-08-31。
国家自然科学基金资助项目（51707115）。



(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

模型的电力系统随机调度策略。文献[8]介绍了数据驱动方法在最优潮流（optimal power flow，OPF）问题中的应用，并未对随机变量建模及对应的优化问题求解方法做深入讨论。

本文重点探讨数据驱动的不确定性因素建模以及优化调度方法，系统梳理了基于数据的随机优化、鲁棒优化和DRO在电力系统调度中的应用现状。首先，介绍随机优化中基于数据的随机变量概率分布建模方法。其次，总结数据驱动的不确定性集合建模及其鲁棒优化问题求解方法。然后，阐述基于数据的概率分布模糊集构建方法，并分析对应的DRO建模、求解方法以及在电力系统调度中的应用场景。最后，结合当前研究并对数据驱动的电力系统优化调度进行总结与展望。

## 1　数据驱动的随机优化

随机优化方法广泛应用于解决考虑不确定性因素的电力系统决策问题。典型的电力系统随机调度问题包括随机OPF[9-11]、随机经济调度[12-14]以及随机机组组合[15-17]等。考虑到电力系统日前-实时的调度方式，当前应用最为广泛的为两阶段/多阶段随机优化，不同文献中的随机调度建模方式不同，具体可参考文献[5]。下面以一种常用的随机机组组合问题为例，阐述随机优化调度的建模思路。考虑到大型常规火电机组无法快速启停，而机组出力能够根据实际负荷大小以及可再生能源发电情况进行调整，因此针对日前调度的两阶段随机机组组合问题可表示为：

$$\min_{x\in X} g(\boldsymbol{x}) + E_P\left(\min_{\boldsymbol{y}\in\boldsymbol{\Omega}(\boldsymbol{x},\boldsymbol{\xi})} f(\boldsymbol{y})\right) \tag{1}$$

式中：$\boldsymbol{x}$为第1阶段决策变量，表示机组启停计划；$\boldsymbol{X}$为$\boldsymbol{x}$的可行域；$g(\boldsymbol{x})$为第1阶段优化问题的目标函数；$\boldsymbol{\xi}$为随机变量，表示可再生能源发电与负荷的不确定性；$P$为$\boldsymbol{\xi}$的概率分布；$\boldsymbol{y}$为第2阶段决策变量；$f(\boldsymbol{y})$为第2阶段优化问题的目标函数；$\boldsymbol{\Omega}(\boldsymbol{x},\boldsymbol{\xi})$为$\boldsymbol{y}$的可行域；$E_P(\cdot)$表示期望值。

由式(1)可知，常规机组出力根据第1阶段决策变量$\boldsymbol{x}$和不确定性因素$\boldsymbol{\xi}$的具体实现而决定。$g(\boldsymbol{x})$为第1阶段优化问题的目标函数，表示机组启停成本；$f(\boldsymbol{y})$为第2阶段优化问题的目标函数，表示机组发电成本。因此，优化问题的目标函数为机组启停成本与机组发电成本期望值之和最小。对于随机优化问题(式(1))，通过对随机变量进行采样并进行场景缩减，获得典型的运行场景及其对应概率，从而将随机优化问题转换为基于场景的优化问题进行求解，即可获得确定性的日前机组启停计划。针对发电与备用优化等其他调度问题，可采用类似的方式建立考虑不确定性因素的随机优化问题，并获得确定性的调度方案。

在传统随机调度中，一般假设随机变量服从给定的概率分布[18-19]（例如，假设风电预测误差服从正态分布），以实现不确定性因素建模。但是，不同地点和时间尺度的可再生能源发电功率变化特性不同，且处于相邻位置的可再生能源发电功率之间具有复杂的时空相关性，因此正态分布、威布尔分布等参数概率分布模型往往难以准确描述不确定性因素的实际变化。基于实际数据建立更准确的不确定性因素模型，能提高决策方案的适用性。改进的不确定性因素建模方法主要分为以下几类。

1）非参数概率模型

非参数概率分布模型不限定随机变量的分布特征和参数，而从随机变量的样本中获取其统计信息，相比于参数概率模型具有更高的准确性。文献[20]基于扩散核密度估计，建立风速的非参数概率模型。所提出的方法能够准确拟合实际风速的概率分布。文献[21]结合核密度估计和自回归滑动平均模型，建立风电功率的概率分布模型，用于解决月度机组组合与短期调度协同优化问题。文献[22]基于可再生能源发电功率的非参数概率模型，建立机会约束随机优化模型，以解决储能系统的规划与运行问题。相比于确定性优化方法以及基于高斯分布的机会约束随机优化方法，所提基于数据的随机优化方法考虑了实际光伏发电数据，得到的运行方案具有更优的经济性。

2）随机过程模型

随机过程用于描述随机变量随时间的变化特性，常用于可再生能源发电功率以及负荷预测。近年来，有学者研究了基于数据的随机过程建模方法，并将其应用于随机优化调度中。文献[23-24]提出了基于可再生能源发电数据与Karhunen-Loeve展开的高斯过程建模方法，以描述可再生能源发电功率的时空变化特性。文献[25]研究了基于高斯过程仿真器的随机调度问题求解方法，相比于蒙特卡洛模拟法，该方法在保证建模精度的基础上，显著提高了随机问题的求解效率。

3）基于人工智能的场景生成方法

人工智能方法具备较强的数据特征挖掘能力，其基于已有数据直接生成符合时空特性的不确定性场景，而无须采用“概率分布建立-样本获取-场景缩减”的方式获得典型场景。人工智能方法的优势在于其基于实际数据，而非拟合的概率分布，生成的场景能较好地反映随机变量的时空特性，所得调度



(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

结果在实际系统中具有更好的适应性。文献[26-27]利用生成对抗网络(generative adversarial network,GAN)学习历史数据的特性,并生成新的可再生能源发电功率场景。文献[27]基于GAN所得到的场景,构建微电网电源容量的随机优化配置模型,并验证了其相比于基于典型场景的配置方案的优越性。文献[28]提出了基于条件变分编码器的场景生成方法,可无监督地学习风电、光伏训练数据的时间、空间及波动性特点,并按条件高效地生成符合观测特点的数据。

综上,相比于参数概率分布模型,基于数据的随机变量模型更准确地描述了可再生能源发电的变化特性。因此,数据驱动的随机优化方法提高了调度方案的经济性与安全性。但是,数据驱动的随机优化方法未能解决调度方案在样本外表现较差的问题,并且优化问题规模较大、求解效率相对较低。该类方法适用于解决关注经济性的中长期与日前调度问题。

## 2 数据驱动的鲁棒优化

相比于随机优化,鲁棒优化不需要设定不确定性因素的概率分布函数,而采用不确定性集合表示其变化范围,并寻求对不确定性因素的所有实现都有良好性能的解[29-30]。传统鲁棒优化根据不确定性集合中的最劣场景直接进行决策,因此优化结果的保守性较强[31]。自适应鲁棒优化(adaptive robust optimization,ARO)的决策过程基于随机变量的实际变化进行调整,近年来在电力系统调度问题中取得了较好的应用效果[32-33]。基于ARO的两阶段调度问题可表示为:

$$\min_{x\in X} g(\boldsymbol{x})+\max_{\xi\in U}\left(\min_{y\in\Omega(x,\xi)} f(\boldsymbol{y})\right) \tag{2}$$

式中:$\boldsymbol{U}$为随机变量$\boldsymbol{\xi}$的不确定性集合。

由式(2)可知,不确定性集合的设置显著影响鲁棒优化结果。目前最为常用的不确定性集合是含预算参数的多面体不确定性集[31],即

$$\boldsymbol{U}=\left\{\boldsymbol{\xi}\middle|\xi_i=\mu_i+\Delta\xi_i z_i \quad -1\leqslant z_i\leqslant 1,\sum_i|z_i|\leqslant\Gamma,\forall i\right\} \tag{3}$$

式中:$\xi_i$为第$i$个随机变量;$\mu_i$为$\xi_i$的期望;$\Delta\xi_i$为$\xi_i$的最大变化幅度;$z_i$为整数变量;$\Gamma$为不确定性预算参数,通过调整$\Gamma$取值改变不确定性集合的大小。

在含多个随机变量的优化问题中,仅考虑不确定性因素的上下限难以反映其真实变化范围,决策方案具有较强保守性[7,34]。文献[35]介绍了其他不确定性集合建模方法,例如考虑随机变量相关性的椭球不确定性集合。近年来,有学者尝试从数据中挖掘随机变量变化范围,提出了各种数据驱动的不确定性集合构建方法,以降低鲁棒优化的保守性。

1)多面体不确定性集合

文献[36]对鲁棒调度中的多面体不确定性集合进行精细化建模,根据风机出力的实时数据,并考虑随机变量的变化范围和时序耦合特性,建立数据驱动的动态不确定性集合为:

$$\boldsymbol{U}=\left\{\boldsymbol{\xi}_t\middle|\underline{\xi}_t(\boldsymbol{\xi}_{t-1})\leqslant\boldsymbol{\xi}_t\leqslant\overline{\xi}_t(\boldsymbol{\xi}_{t-1}) \quad \forall t\right\} \tag{4}$$

式中:$\boldsymbol{\xi}_t$为$t$时刻的随机变量;$\overline{\xi}_t$和$\underline{\xi}_t$分别为$t$时刻随机变量$\boldsymbol{\xi}_t$的上、下限,其值与$t-1$时刻随机变量的实现相关。

文献[37-38]针对电力系统调度与规划问题,采用核密度估计建立源荷的概率密度函数,然后基于分位数构建含预算参数的不确定性集合,即

$$\boldsymbol{U}=\left\{\boldsymbol{\xi}\middle|\begin{array}{l}F_i(\alpha)\leqslant\xi_i\leqslant F_i(1-\alpha) \quad \forall i\\ \sum_i(1-\eta_i\Gamma)\mu_i\leqslant\sum_i\xi_i\leqslant\sum_i(1+\eta_i\Gamma)\mu_i\end{array}\right\} \tag{5}$$

式中:$F_i(\alpha)$为置信度$\alpha$下$\xi_i$的分位数;$\eta_i$为$\xi_i$的相对偏差值。上述参数都可以通过核密度估计得到。

考虑到可再生能源发电复杂的不确定性,仅采用一个集合描述不确定性因素变化范围可能不够准确。因此,文献[39]采用Dirichlet过程混合模型方法对风电数据进行聚类,然后将每个聚类建立为一个基本不确定性集合$\boldsymbol{U}_j$,最终将风电不确定性集合表示为所有基本不确定性集合的并集。

$$\boldsymbol{U}=\boldsymbol{U}_1\cup\boldsymbol{U}_2\cup\cdots\cup\boldsymbol{U}_j\cup\cdots\cup\boldsymbol{U}_J \tag{6}$$

基本不确定集合$\boldsymbol{U}_j(j=1,2,\cdots,J)$为:

$$\boldsymbol{U}_j=\left\{\boldsymbol{\xi}_j\middle|\boldsymbol{\xi}_j=\boldsymbol{\mu}_j+s_j\sqrt{\boldsymbol{\Psi}_j}\,\Lambda_j\boldsymbol{\delta} \quad \|\boldsymbol{\delta}\|_\infty\leqslant 1,\|\boldsymbol{\delta}\|_1\leqslant\Gamma_j\right\} \tag{7}$$

式中:$\boldsymbol{\xi}_j$为不确定集合$\boldsymbol{U}_j$中的随机变量;$\boldsymbol{\mu}_j$为随机变量$\boldsymbol{\xi}_j$的期望;$s_j$和$\boldsymbol{\Psi}_j$为第$j$个基本不确定性集合的参数;$\Lambda_j$为比例因子;$\boldsymbol{\delta}$为随机噪声;$\|\cdot\|_\infty$和$\|\cdot\|_1$分别表示求无穷范数和1范数函数;$\Gamma_j$为不确定集合$\boldsymbol{U}_j$的不确定性预算参数,通过调整$\Gamma_j$的取值控制$\boldsymbol{\delta}$的波动范围,从而改变不确定性集合的大小。

基于不确定性集合(式(7))的鲁棒优化问题为:

$$\min_{x\in X} g(\boldsymbol{x})+\max_{j=1,2,\cdots,J}\left(\max_{\xi_j\in U_j}\left(\min_{y\in\Omega(x,\xi_j)} f(\boldsymbol{y})\right)\right) \tag{8}$$

其中,第2阶段优化问题针对所有基本不确定



(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

性集合中的最劣场景进行决策。

2）椭球不确定性集合

文献[40]在配电网优化问题中，建立了考虑风电功率相关性的椭球不确定集合，即

$$\boldsymbol{U}=\left\{\boldsymbol{\xi}\middle|(\boldsymbol{\xi}-\boldsymbol{\mu}_0)^{\mathrm{T}}\boldsymbol{\Sigma}_0^{-1}(\boldsymbol{\xi}-\boldsymbol{\mu}_0)\leqslant\Gamma\right\} \tag{9}$$

式中：$\boldsymbol{\mu}_0$为随机变量$\boldsymbol{\xi}$的期望；$\boldsymbol{\Sigma}_0$为随机变量$\boldsymbol{\xi}$的协方差矩阵。

文献[41]在鲁棒机组组合问题中，考虑风电场出力的动态相关性，基于量测数据建立风电功率的椭球不确定性集合，相比于多面体不确定性集合，降低了鲁棒优化结果的保守性。文献[42]研究了基于最小体积椭球（minimum volume enclosing ellipsoid，MVEE）的不确定性集合建模方法，通过求解二次规划问题，建立包含所有数据同时体积最小的椭球体。文献[43]采用MVEE建立风电功率的椭球不确定性集合，研究了基于椭球不确定性集合的鲁棒调度问题，并提出了一种无效约束删减策略以减小优化问题的求解复杂度。

相比于多面体不确定性集合，椭球不确定性集合考虑了随机变量之间的相关性，更适用于处于相邻地址位置的风电场以及光伏电站的出力建模。另一方面，椭球不确定集合表示为二次约束条件，这增加了优化问题的求解难度。

3）基于场景构建不确定性集合

除了多面体和椭球不确定性集合之外，另一种较为常用的方法是基于极端场景构建不确定性集合。文献[44]提出了一种基于极端场景筛选的自适应不确定性集合建模方法，并应用于主动配电网经济调度。首先，基于配电网的源荷历史数据，建立椭球不确定性集合，并选取若干边界点作为初始极端场景。然后，引入比例因子，对以初始极端场景为顶点所构成的凸集进行扩展，直至覆盖所有数据。最后，获得校正后的不确定性集合。所建立的鲁棒优化问题可表示为基于极端场景的确定性模型，即

$$\begin{cases}\max\limits_{\boldsymbol{\xi}_n\in U_{\mathrm{new}}}\left(\min\limits_{\boldsymbol{x},\boldsymbol{y}_n}f(\boldsymbol{x},\boldsymbol{y}_n,\boldsymbol{\xi}_n)\right)\\ \text{s.t.}\quad \boldsymbol{A}(\boldsymbol{x},\boldsymbol{y}_n,\boldsymbol{\xi}_n)=0 \qquad n=1,2,\cdots,N\\ \qquad \boldsymbol{B}(\boldsymbol{x},\boldsymbol{y}_n,\boldsymbol{\xi}_n)\leqslant 0 \qquad n=1,2,\cdots,N\end{cases} \tag{10}$$

式中：$\boldsymbol{\xi}_n$为第$n$个极端场景中的随机变量；$U_{\mathrm{new}}$为校正后的极端场景集合，包含$N$个极端场景；$\boldsymbol{y}_n$为第$n$个极端场景下的第2阶段决策变量；$\boldsymbol{A}(\cdot)$和$\boldsymbol{B}(\cdot)$为优化模型的约束条件。算例分析表明，采用筛选出的极端场景代替传统不确定性集合参与优化决策，在保证决策方案鲁棒性的同时降低了其保守性。

另一种基于极端场景的不确定性集合构建方法不事先假定不确定性集合的形状，而是将不确定集合表示为历史场景的凸包，即

$$\boldsymbol{U}=\left\{\boldsymbol{\xi}\middle|\boldsymbol{\xi}=\sum_{n=1}^{N}\alpha_n\boldsymbol{\xi}_n \quad \sum_{n=1}^{N}\alpha_n=1,\alpha_n\geqslant 0\right\} \tag{11}$$

式中：$\alpha_n$为第$n$个极端场景的权重参数。

文献[45]采用式(11)描述可再生能源发电功率的变化范围，并基于式(2)建立考虑高比例可再生能源的机组组合鲁棒优化模型。针对该“min-max-min”3层优化问题，首先将原问题转换为混合整数线性规划问题，然后采用列约束生成（column-and-constraints generation，C&CG）算法进行求解。文献[46]基于同样的不确定性因素建模方法，研究了考虑光伏发电不确定性的配电网电压/无功优化方法，制定调压器和电容器组的最优控制策略，降低了网损和节点电压越限概率。

综上，数据驱动鲁棒优化的优点在于数量需求量较低、样本外表现较好。但是，由于在不确定性因素建模过程中未考虑数据所表征的统计信息（概率分布、统计矩等），优化结果的保守性仍然较强。数据驱动的鲁棒优化适用于解决关注安全性的日前与日内调度问题。

## 3　数据驱动的DRO

在鲁棒优化中，虽然基于数据的不确定性集合较为准确地反映了不确定性因素的变化范围，但是其仍然基于最差场景进行决策，没有考虑随机变量的概率分布模型。近年来，DRO被提出来克服鲁棒优化的不足。DRO无须设定概率分布的类型及参数，而是基于数据建立概率分布的模糊集合，并针对模糊集中最劣概率分布进行决策。因此，DRO既充分利用了随机变量的统计信息，又保障了优化结果的鲁棒性。

构建概率分布模糊集是求解DRO问题的关键与前提，常用方法包括基于统计矩和基于距离的概率分布模糊集构建方法。

### 3.1　基于统计矩的DRO

统计矩反映了随机变量的统计信息。例如，一阶原点矩为随机变量的期望，两阶中心矩为随机变量的方差。相比于完整的概率分布函数，随机变量的统计矩信息较容易获得。文献[47]针对考虑风电不确定性的经济调度问题，首先设定风电预测误差的概率分布模糊集$\mathcal{D}_{\mathrm{mo},1}$，其中所有概率分布的期望和方差都等于给定值，即



(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

$$\mathcal{D}_{\mathrm{mo},1}=\left\{P(\boldsymbol{\xi})\left|\begin{array}{l}\int P(\boldsymbol{\xi})\mathrm{d}\boldsymbol{\xi}=1\\ \boldsymbol{E}_P(\boldsymbol{\xi})-\boldsymbol{\mu}_0=0\\ \boldsymbol{E}_P((\boldsymbol{\xi}-\boldsymbol{\mu}_0)(\boldsymbol{\xi}-\boldsymbol{\mu}_0)^{\mathrm{T}})=\boldsymbol{\Sigma}_0\end{array}\right.\right\} \tag{12}$$

式中：$P(\cdot)$为$\boldsymbol{\xi}$的概率密度函数；$\boldsymbol{E}_P(\cdot)$为随机变量$\boldsymbol{\xi}$的期望。

然后，建立发电和备用协同优化的两阶段DRO问题。第1阶段问题考虑风电预测值，优化目标为常规机组发电成本与备用成本之和最小；第2阶段问题针对风电的不确定性，优化目标为最劣概率分布下的再调度成本期望值最小。所建立的两阶段DRO问题可表示为：

$$\min_{\boldsymbol{x}\in X} g(\boldsymbol{x})+\max_{P\in\mathcal{D}_{\mathrm{mo},1}}\left(E_P\left(\min_{\boldsymbol{y}\in\boldsymbol{\Omega}(\boldsymbol{x},\boldsymbol{\xi})} f(\boldsymbol{y})\right)\right) \tag{13}$$

DRO将随机变量的概率分布也作为优化问题的决策变量，这导致式(13)无法直接求解。对此，文献[47]采用线性规划、二次规划和半正定规划交替求解的方式解决DRO问题。仿真结果表明，相比于鲁棒优化，DRO降低了调度方案的保守性。

考虑到随机变量概率分布的统计矩与设定值之间可能存在偏差，文献[48]采用式(14)建立可再生能源发电功率的概率分布模糊集$\mathcal{D}_{\mathrm{mo},2}$。

$$\mathcal{D}_{\mathrm{mo},2}=\left\{P(\boldsymbol{\xi})\left|\begin{array}{l}\int P(\boldsymbol{\xi})\mathrm{d}\boldsymbol{\xi}=1\\ (\boldsymbol{E}_P(\boldsymbol{\xi})-\boldsymbol{\mu}_0)^{\mathrm{T}}\boldsymbol{\Sigma}_0^{-1}(\boldsymbol{E}_P(\boldsymbol{\xi})-\boldsymbol{\mu}_0)\leqslant\varepsilon_1\\ \boldsymbol{E}_P((\boldsymbol{\xi}-\boldsymbol{\mu}_0)(\boldsymbol{\xi}-\boldsymbol{\mu}_0)^{\mathrm{T}})\leqslant\varepsilon_2\boldsymbol{\Sigma}_0\end{array}\right.\right\} \tag{14}$$

式中：$\varepsilon_1$和$\varepsilon_2$分别为均值和方差的偏移约束参数，按照决策者的风险偏好进行调整，其值越大，调度方案的鲁棒性和保守性越强。

基于上述概率分布模糊集构建方法，文献[49-50]采用DRO解决考虑不确定性因素的机组组合问题，文献[51]研究了考虑风电功率矩不确定的实时调度方法。除了关于大电网优化调度的研究，也有学者采用DRO解决配电网有功-无功协调调度[52]、交直流混合微电网调度[53]、虚拟电厂调度[54]以及电-气联合系统需求响应问题[55]。常用的求解方式是将原问题等效或者近似转换为易于求解的凸规划问题，再采用数学优化求解器进行求解。

在DRO建模中，除了在目标函数中考虑最劣概率分布下的运行成本期望值最小外，也可以采用机会约束的形式加以描述。文献[56]基于概率分布模糊集，建立随机OPF的联合机会约束条件，即

$$\min_{P\in\mathcal{D}} P\{\boldsymbol{\xi}\in\boldsymbol{\Xi}|\boldsymbol{M}(\boldsymbol{x},\boldsymbol{\xi})\leqslant 0\}\geqslant 1-\varepsilon_{\mathrm{c}} \tag{15}$$

式中：$\boldsymbol{\Xi}$为随机变量$\boldsymbol{\xi}$的集合；$\varepsilon_{\mathrm{c}}$为机会约束不成立的风险水平；$\boldsymbol{M}=[m_1,m_2,\cdots,m_p]$，为机会约束条件组成的联合矩阵；$\mathcal{D}$为概率分布模糊集。

式(15)表示对于模糊集中的所有概率分布，都满足给定风险水平下的机会约束条件。已有学者采用计及机会约束的DRO解决OPF[56]、电网-分布式能源联合规划[57]以及孤岛微电网能量管理[58]等问题。包含约束式(15)的优化问题难以直接求解，可采用等效重构方法转换为线性规划[57]、半正定规划或者二阶锥规划[56,58]的形式加以求解。

总体来说，考虑到可再生能源发电出力的统计矩信息较易获得，基于统计矩的DRO方法已经在电力系统调度中得到较多应用。相比于鲁棒优化，基于统计矩的DRO考虑了随机变量的统计信息，降低了调度方案的保守性。该类方法适用于随机变量具有较强相关性的场合[59]，可用于解决关注经济性与安全性的日前及日内调度问题。

### 3.2 基于距离的DRO

不同随机变量可能拥有相同的统计矩，因此若仅采用统计矩建立概率分布模糊集，可能会导致集合中包含与实际概率模型相差很大的概率分布函数。实际上，除了统计矩外，可基于数据建立随机变量的经验概率分布，通过定义其他概率分布与经验概率分布之间的距离，构建基于距离的概率分布模糊集。

#### 3.2.1 基于phi散度的概率分布模糊集

phi散度是一种衡量2个概率分布之间距离的参数，可用于构建以经验概率分布为中心的概率分布模糊集。相比于基于统计矩的模糊集，基于phi散度的模糊集利用了更多统计信息。基于phi散度的概率分布模糊集$\mathcal{D}_{\mathrm{phi}}$可描述为：

$$\mathcal{D}_{\mathrm{phi}}=\{P\in D\left|\quad d_{\mathrm{p}}(P\|P_0)\leqslant\eta_\alpha\right.\} \tag{16}$$

式中：$D$为所有随机变量概率分布的集合；$\eta_\alpha$为置信度$\alpha$下的散度范围；$P_0$为随机变量的经验分布；$d_{\mathrm{p}}(\cdot)$为2个概率分布的phi散度计算函数。典型的phi散度包括变换距离和Kullback-Leibler(KL)散度[60]。

变换距离描述2个列向量间的范数距离。文献[61]构建了基于变换距离的概率分布模糊集。首先，采用蒙特卡洛模拟采样与场景缩减获得可再生能源发电功率的$N$个场景及其对应概率$\boldsymbol{P}_0=[p_{01},p_{02},\cdots,p_{0n},\cdots,p_{0N}]^{\mathrm{T}}$，然后建立模糊集包含所有满足式(17)或式(18)的离散概率分布$\boldsymbol{P}=[p_1,p_2,\cdots,p_n,\cdots,p_N]^{\mathrm{T}}$

$$d_{\mathrm{L1}}(\boldsymbol{P}\|\boldsymbol{P}_0)\triangleq\sum\left|\boldsymbol{P}-\boldsymbol{P}_0\right|\leqslant\eta_{\mathrm{L1}} \tag{17}$$



(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

$$d_{L\infty}(\boldsymbol{P}\|\boldsymbol{P}_0)\triangleq\max\left(\left|\boldsymbol{P}-\boldsymbol{P}_0\right|\right)\leqslant\eta_{L\infty}\tag{18}$$

式中：$d_{L1}(\cdot)$和$d_{L\infty}(\cdot)$分别为求L1范数距离和无穷范数距离函数。式(17)和式(18)分别对应于与经验分布的L1范数和无穷范数距离小于距离参数$\eta_{L1}$和$\eta_{L\infty}$的离散概率分布。

文献[61]构建了风险规避的随机机组组合问题，并且推导了距离参数$\eta_{L1}$和$\eta_{L\infty}$与样本规模之间的关系：随着样本规模的增加，$\eta_{L1}$和$\eta_{L\infty}$逐渐减小，这使得DRO结果的保守性逐渐降低。在此基础上，文献[62-63]建立了数据驱动的机会约束分布鲁棒机组组合模型，将机会约束条件转换为条件风险价值(CVaR)形式进行求解，相比于随机优化和鲁棒优化，DRO模型获得的方案运行成本更低。基于范数距离的DRO也被应用于解决配电网无功优化[64]和电-气能源系统的联合调度[65]等问题。

对于式(17)和式(18)所示的概率分布模糊集，其对应的DRO问题基于离散场景，优化问题规模较大，求解效率较低。为克服计算效率低的缺点，文献[66-67]针对无功优化和机组组合问题，提出了改进的C&CG算法，将双层优化问题分解为多个并行求解的子问题，避免了大量对偶变量和约束条件，提高了优化问题求解效率。针对输电网扩展规划问题，文献[68]提出了结合C&CG算法与Benders分解的分解算法，对比传统C&CG算法和Benders分解算法，其求解效率更高。

KL散度又称为相对熵，表示2个概率分布间信息熵的差值。文献[69-72]给出了连续和离散随机变量的KL散度($d_{KLd}$和$d_{KLc}$)计算公式分别如式(19)和式(20)所示。

$$d_{KLd}(P\|P_0)=\int P(\boldsymbol{\xi})\ln\frac{P(\boldsymbol{\xi})}{P_0(\boldsymbol{\xi})}\mathrm{d}\boldsymbol{\xi}\tag{19}$$

$$d_{KLc}(\boldsymbol{P}\|\boldsymbol{P}_0)=\sum_{n=1}^{N}p_n\ln\frac{p_n}{p_{0n}}\tag{20}$$

已有研究采用式(19)和式(20)表示风电、光伏发电的不确定性，研究了基于DRO的机组组合[69]、热泵储能参与日前经济调度[70]以及电-气-热联合的能量路由器容量规划等问题[71]。文献[72]针对分布式能源运行问题，引入机会约束表示电动汽车充放电功率和容量的上下限约束，取得了具有较高经济性的调度方案。对于基于KL散度的DRO模型，通常采用等效重构、对偶变换等方法，将原问题转化为凸优化问题进行求解[71]。

基于phi散度的模糊集对数据的需求量低，优化结果样本外表现较好，但通常用于对离散概率分布进行建模。基于phi散度的DRO适用于具有典型运行场景，且关注经济性与安全性的日前与日内调度问题。

### 3.2.2　基于ζ结构概率指标的概率分布模糊集

在phi散度模型中，大部分phi散度难以满足概率分布的三角不等式，并且不具备对称属性。因此，基于ζ结构概率指标被提出，以克服phi散度在概率分布建模中不严谨的问题[73]。ζ结构概率指标中应用最为广泛的为Wasserstein距离，其定义为概率分布空间中，从概率分布$P_0$移动到概率分布$P$的距离范数$d_w$为：

$$d_w(P_0,P)=\inf\left(\int\|\boldsymbol{\xi}_1-\boldsymbol{\xi}_2\|\Pi(\mathrm{d}\boldsymbol{\xi}_1,\mathrm{d}\boldsymbol{\xi}_2)\right)\tag{21}$$

式中：$\boldsymbol{\xi}_1$为服从概率分布$P_0$的随机变量；$\boldsymbol{\xi}_2$为服从概率分布$P$的随机变量；$\Pi(\cdot)$为$\boldsymbol{\xi}_1$和$\boldsymbol{\xi}_2$的联合概率分布；$\|\cdot\|$表示求范数函数；inf(·)表示求下确界函数。

文献[74]基于Wasserstein距离建立可再生能源发电功率的概率分布模糊集，如式(22)所示。考虑可再生能源发电功率变化引起的系统运行约束越限风险，建立了输电网和配电网OPF的DRO问题，即

$$\mathcal{D}_{wa}=\{P\in D\,|\,d_w(P_0,P)\leqslant\varepsilon_W\}\tag{22}$$

式中：$\varepsilon_W$为模糊集半径。

基于Wasserstein距离的DRO问题与前文所述其他类型的DRO问题形式相同，仅仅是模糊集建模方法有所不同。同样，由于概率分布函数也为决策变量，基于Wasserstein的DRO问题无法直接求解。对此，文献[74]将DRO问题变换为基于场景的确定性优化问题进行求解。文献[75]研究了基于Wasserstein距离的机会约束DRO求解方法。文献[76]建立了电-气联合系统的分布鲁棒OPF问题，并将其转换为凸优化问题进行求解。除了用于解决OPF问题，基于Wasserstein距离的DRO方法也被用于解决随机经济调度、机组组合等问题[77-78]。因为基于Wasserstein距离的DRO问题需要转换为基于场景的优化问题进行求解，所以优化问题规模随着场景个数的增加而增大。对此，文献[79-80]建立了DRO问题的近似问题，在场景个数较多时仍然具有较高的求解效率。

综上所述，基于Wasserstein距离的DRO方法可充分挖掘数据所表征的统计信息，并且所得调度结果的样本外表现较好，但是其建模方式导致优化问题无法直接求解，同时求解效率受到样本规模大小的影响。基于Wasserstein距离的DRO方法适用于解决关注经济性与安全性的日前与日内调度问



(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

题。附录A表A1总结了各种数据驱动的调度方法，分析了数据驱动的随机优化、鲁棒优化以及DRO的不确定性因素建模方法、优缺点及适用场合。

## 4 挑战与展望

上文总结了数据驱动的随机优化、鲁棒优化和DRO在电力系统调度中的应用现状。基于以上分析讨论，本章归纳数据驱动的电力系统优化运行所面临的挑战，并对未来研究提出展望。

1)复杂不确定性因素建模

当前，DRO是考虑不确定性因素的电力系统调度的主要研究领域。在后续研究中，可深入研究DRO的随机变量建模方法，更为准确地刻画可再生能源发电的不确定性，例如，考虑源荷时空变化相关性的不确定性因素建模[80]、同时考虑矩信息与距离信息的概率分布模糊集建模[81]等等。另外，现有研究主要关注以随机源荷为代表的连续随机变量，对设备或者线路故障等离散随机变量建模的研究较少。实际上，相比于源荷波动，线路故障对系统运行的影响更为显著。因此，需要考虑连续与离散随机变量的耦合，研究包含不同类型随机变量的概率分布模糊集构建方法。

DRO的概率分布模糊集半径的大小决定了决策方案的保守性。现有研究中一般根据经验或者灵敏度分析设定模糊集半径，缺乏相关的理论方法作为支撑。在后续研究中，可基于交叉验证、样本规模和置信度关系等方法选择最优半径，探讨概率分布模糊集半径大小对电力系统调度结果的影响。

2)综合能源系统不确定性管理

综合能源系统为能源互联网能源侧的重要部分，其基于多能互补与能源梯级利用机制，对“源-网-荷-储”进行协同调度，促进可再生能源消纳，实现能源供需双方的互利共赢。已有文献研究了综合能源系统建模与运行问题[55,70,73]。电、气、热各个环节中都存在不确定性因素，当前对各类不确定性因素的耦合机理及其对综合能源系统运行影响的研究相对较少。为准确分析不确定性环境下能源系统运行规律，需要基于数据分析综合能源系统运行机理，研究综合能源系统的不确定性管理方法，并完善综合能源系统的协同运行机制以及分层分区协调调度技术。

相比于电力系统调度，综合能源系统调度所包含的随机变量维度更高，优化问题规模更大。在考虑高维不确定性因素的能源系统调度问题中，并非所有不确定性因素都会对系统运行造成显著影响。因此可采用全局灵敏度分析辨识影响系统运行的关键不确定性因素[82-84]。通过保留关键不确定性因素，减少随机优化问题中随机变量的个数[85-87]，降低调度问题的求解难度，提高优化问题求解效率。并且，对关键不确定性因素采取合适的监测和控制手段(例如配置量测装置、储能装置等)，可有效降低系统运行的不确定性。

3)人工智能技术与优化方法结合

近年来，随着计算机计算能力的提升和人工智能技术的发展，人工智能技术逐步应用于电力系统不确定性建模以及优化调度中，其具有数据特征挖掘能力强、对模型依赖程度低的优点。现有研究一般基于新能源发电功率的历史数据建立不确定性因素，而监督学习、非监督学习等方法可获得新能源发电的非参数概率预测模型。因此，需要将概率预测技术与优化调度方法相融合，从数学理论上构建基于概率预测的决策方法，从而提升系统应对未来实际不确定性因素的能力。

除监督学习、非监督学习外，强化学习在电力系统运行中也具有良好的应用前景。近年来受到学者关注的深度强化学习结合了深度学习的感知能力和强化学习的决策能力，其基于多层网络变换，学习大规模数据潜在特征，并基于奖赏和动作的反复调整，从环境中学习决策方向，直至实现最优目标[88]。深度强化学习能够用于解决部分可观或者复杂系统的决策问题，已经在电动汽车充放电决策、电压控制[89]、频率控制[90]等方面展现出较好应用效果。未来能源系统具有复杂的多级结构，能源系统运行存在难以建立完整数学模型的难题，并且需要解决多层、多区域调度问题。对此，需要将深度强化学习与随机优化、鲁棒优化、DRO等方法有机结合，考虑能源系统中不同部分的差异化调度，提出多层级协调调度方法，解决不确定性环境下复杂系统的优化运行问题。

## 5 结语

可再生能源的接入给电力系统运行带来了显著的不确定性，而大量的可再生能源发电数据又为系统运行提供了数据支撑，数据驱动的不确定性决策方法在电力系统运行中得到了广泛应用。本文总结了数据驱动优化方法在不确定性环境中电力系统调度的应用现状：对于随机优化与鲁棒优化，基于数据可建立更为准确的不确定性因素模型，从而提高决策方案的适应性；对于DRO，挖掘数据统计信息，构



(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

建随机变量的概率分布模糊集是其求解的关键，主要分为基于统计矩与基于距离的方法；相比于随机优化与鲁棒优化，DRO即充分利用了随机变量的统计信息，又保障了优化结果的鲁棒性。最后，本文从复杂不确定性因素建模、综合能源系统不确定性管理、人工智能技术与优化方法结合等3个方面对未来研究进行了展望。希望本文工作可为大规模可再生能源接入下的能源系统优化运行提供参考。

**附录见本刊网络版（http://www.aeps-info.com/aeps/ch/index.aspx），扫英文摘要后二维码可以阅读网络全文。**

## 参 考 文 献


[1] International Renewable Energy Agency. Global energy transformation: a roadmap to 2050 [EB/OL]. [2020-06-01]. http://www.doc88.com/p-0764853879965.html.

[2] 国家发展和改革委员会能源研究所.中国2050高比例可再生能源发展情景暨路径研究[EB/OL].[2020-06-01].https://max.book118.com/html/2018/0225/154636939.shtm.
Energy Research Institute of National Development and Reform Commission. High renewable energy penetration scenario and road map study in 2050 China[EB/OL]. [2020-06-01]. https://max.book118.com/html/2018/0225/154636939.shtm.

[3] NING C, YOU F. Data-driven stochastic robust optimization: general computational framework and algorithm leveraging machine learning for optimization under uncertainty in the big data era [J]. Computers & Chemical Engineering, 2018, 111: 115-133.

[4] SHANG C, YOU F. Distributionally robust optimization for planning and scheduling under uncertainty [J]. Computers & Chemical Engineering, 2018, 110: 53-68.

[5] ZHENG Q P, WANG J, LIU A L. Stochastic optimization for unit commitment: a review [J]. IEEE Transactions on Power Systems, 2014, 30(4): 1913-1924.

[6] TAN W S, SHAABAN M, AB KADIR M Z A. Stochastic generation scheduling with variable renewable generation: methods, applications, and future trends [J]. IET Generation, Transmission & Distribution, 2019, 13(9): 1467-1480.

[7] 于丹文，杨明，翟鹤峰，等.鲁棒优化在电力系统调度决策中的应用研究综述[J].电力系统自动化，2016，40(7)：134-143.
YU Danwen, YANG Ming, QU Hefeng, et al. An overview of robust optimization used for power system dispatch and decision-making [J]. Automation of Electric Power Systems, 2016, 40(7): 134-143.

[8] 刘羽霄，张宁，康重庆.数据驱动的电力网络分析与优化研究综述[J].电力系统自动化，2018，42(6)：157-167.
LIU Yuxiao, ZHANG Ning, KANG Chongqing. A review on data-driven analysis and optimization of power grid [J]. Automation of Electric Power Systems, 2018, 42(6): 157-167.

[9] 易驰韡，胡泽春，宋永华.考虑注入功率分布的随机最优潮流方法[J].电网技术，2013，37(2)：367-371.
YI Chiwei, HU Zechun, SONG Yonghua. A stochastic optimal power flow method considering power injection distributions [J]. Power System Technology, 2013, 37(2): 367-371.

[10] MAULIK A, DAS D. Optimal power dispatch considering load and renewable generation uncertainties in an AC-DC hybrid microgrid [J]. IET Generation, Transmission & Distribution, 2019, 13(7): 1164-1176.

[11] 潘雄，周明，孔晓民，等.风速相关性对最优潮流的影响[J].电力系统自动化，2013，37(6)：37-41.
PAN Xiong, ZHOU Ming, KONG Xiaomin, et al. Impact of wind speed correlation on optimal power flow [J]. Automation of Electric Power Systems, 2013, 37(6): 37-41.

[12] 王豹，徐箭，孙元章，等.基于通用分布的含风电电力系统随机动态经济调度[J].电力系统自动化，2016，40(6)：23-30.
WANG Bao, XU Jian, SUN Yuanzhang, et al. Stochastic dynamic economic dispatch of power systems considering wind power based on versatile probability distribution [J]. Automation of Electric Power Systems, 2016, 40(6): 23-30.

[13] 邓创，鞠立伟，刘俊勇，等.基于模糊CVaR理论的水火电系统随机调度多目标优化模型[J].电网技术，2016，40(5)：1447-1454.
DENG Chuang, JU Liwei, LIU Junyong, et al. Stochastic scheduling multi-objective optimization model for hydro-thermal power system based on fuzzy CVaR theory [J]. Power System Technology, 2016, 40(5): 1447-1454.

[14] LIU X, XU W. Economic load dispatch constrained by wind power availability: a here-and-now approach [J]. IEEE Transactions on Sustainable Energy, 2010, 1(1): 2-9.

[15] 刘斌，刘锋，王程，等.考虑风电场灵活性及出力不确定性的机组组合[J].电网技术，2015，39(3)：730-736.
LIU Bin, LIU Feng, WANG Cheng, et al. Unit commitment considering flexibility and uncertainty of wind power generation [J]. Power System Technology, 2015, 39(3): 730-736.

[16] WU L, SHAHIDEHPOUR M, LI T. Stochastic security-constrained unit commitment [J]. IEEE Transactions on Power Systems, 2007, 22(2): 800-811.

[17] CONSTANTINESCU E M, ZAVALA V M, ROCKLIN M, et al. A computational framework for uncertainty quantification and stochastic optimization in unit commitment with wind power generation [J]. IEEE Transactions on Power Systems, 2011, 26(1): 431-441.

[18] 叶林，李智，孙舶皓，等.基于随机预测控制理论和功率波动相关性的风电集群优化调度[J].中国电机工程学报，2018，38(11)：3172-3183.
YE Lin, LI Zhi, SUN Bohao, et al. Optimal dispatch of system integrated wind farm clusters based on stochastic model predictive control considering temporal correlation of wind power [J]. Proceedings of the CSEE, 2018, 38(11): 3172-3183.

[19] 吴杰康，唐力.含不确定性负荷的水火电力系统随机优化调度[J].中国电机工程学报，2012，32(28)：36-43.
WU Jiekang, TANG Li. Stochastic optimization scheduling method for hydrothermal power systems with stochastic loads [J]. Proceedings of the CSEE, 2012, 32(28): 36-43.




(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

[20] XU X, YAN Z, XU S. Estimating wind speed probability distribution by diffusion-based kernel density method [J]. Electric Power Systems Research, 2015, 121: 28-37.

[21] 元一平,王建学,周锟,等.协同短期调度的新能源电力系统月度机组组合模型与快速求解方法[J].中国电机工程学报,2019,39(18):5336-5345.
YUAN Yiping, WANG Jianxue, ZHOU Kun, et al. Monthly unit commitment model coordinated short-term scheduling and efficient solving method for renewable energy power system[J]. Proceedings of the CSEE, 2019, 39(18): 5336-5345.

[22] AKHAVAN-HEJAZI H, MOHSENIAN-RAD H. Energy storage planning in active distribution grids: a chance-constrained optimization with non-parametric probability functions[J]. IEEE Transactions on Smart Grid, 2016, 9(3): 1972-1985.

[23] SAFTA C, CHEN R L Y, NAJM H N, et al. Efficient uncertainty quantification in stochastic economic dispatch [J]. IEEE Transactions on Power Systems, 2016, 32(4): 2535-2546.

[24] LI J, OU N, LIN G, et al. Compressive sensing based stochastic economic dispatch with high penetration renewables [J]. IEEE Transactions on Power Systems, 2018, 34(2): 1438-1449.

[25] HU Z, XU Y, KORKALI M, et al. Uncertainty quantification in stochastic economic dispatch using Gaussian process emulation [EB/OL]. [2020-06-01]. https://arxiv. org/abs/1909.09266?context=eess.SY.

[26] CHEN Y, WANG Y, KIRSCHEN D, et al. Model-free renewable scenario generation using generative adversarial networks[J]. IEEE Transactions on Power Systems, 2018, 33(3): 3265-3275.

[27] 李康平,张展耀,王飞,等.基于GAN场景模拟与条件风险价值的独立型微网容量随机优化配置模型[J].电网技术,2019,43(5):1717-1725.
LI Kangping, ZHANG Zhanyao, WANG Fei, et al. Stochastic optimization model of capacity configuration for stand-alone microgrid based on scenario simulation using GAN and conditional value at risk[J]. Power System Technology, 2019, 43(5): 1717-1725.

[28] 王守相,陈海文,李小平,等.风电和光伏随机场景生成的条件变分自动编码器方法[J].电网技术,2018,42(6):1860-1867.
WANG Shouxiang, CHEN Haiwen, LI Xiaoping, et al. Conditional variational automatic encoder method for stochastic scenario generation of wind power and photovoltaic system[J]. Power System Technology, 2018, 42(6): 1860-1867.

[29] 魏韡,刘锋,梅生伟.电力系统鲁棒经济调度:(一)理论基础[J].电力系统自动化,2013,37(17):37-43.
WEI Wei, LIU Feng, MEI Shengwei. Robust and economical scheduling methodology for power systems: Part one theoretical foundations [J]. Automation of Electric Power Systems, 2013, 37(17): 37-43.

[30] ZHANG Z, CHEN Y, LIU X, et al. Two-stage robust security-constrained unit commitment model considering time autocorrelation of wind/load prediction error and outage contingency probability of units[J]. IEEE Access, 2019, 7: 25398-25408.

[31] NING C, YOU F. Optimization under uncertainty in the era of big data and deep learning: when machine learning meets mathematical programming [J]. Computers & Chemical Engineering, 2019, 125: 434-448.

[32] BERTSIMAS D, LITVINOV E, SUN A, et al. Adaptive robust optimization for the security constrained unit commitment problem [J]. IEEE Transactions on Power Systems, 2012, 28(1): 52-63.

[33] VERÁSTEGUI F, LORCA Á, OLIVARES D E, et al. An adaptive robust optimization model for power systems planning with operational uncertainty[J]. IEEE Transactions on Power Systems, 2019, 34(6): 4606-4616.

[34] 高昇宇,柳志航,卫志农,等.城市智能光储充电塔自适应鲁棒日前优化调度[J].电力系统自动化,2019,43(20):39-48.
GAO Shengyu, LIU Zhihang, WEI Zhinong, et al. Adaptive robust day-ahead optimal dispatch for urban smart photovoltaic storage and charging tower[J]. Automation of Electric Power Systems, 2019, 43(20): 39-48.

[35] GUAN Y, WANG J. Uncertainty sets for robust unit commitment [J]. IEEE Transactions on Power Systems, 2013, 29(3): 1439-1440.

[36] LORCA A, SUN A. Adaptive robust optimization with dynamic uncertainty sets for multi-period economic dispatch under significant wind [J]. IEEE Transactions on Power Systems, 2014, 30(4): 1702-1713.

[37] HOU W, WEI H, ZHU R. Data-driven multi-time scale robust scheduling framework of hydrothermal power system considering cascade hydropower station and wind penetration [J]. IET Generation, Transmission & Distribution, 2018, 13(6): 896-904.

[38] NING C, YOU F. A data-driven multistage adaptive robust optimization framework for planning and scheduling under uncertainty[J]. AIChE Journal, 2017, 63(10): 4343-4369.

[39] NING C, YOU F. Data-driven adaptive robust unit commitment under wind power uncertainty: a Bayesian nonparametric approach [J]. IEEE Transactions on Power Systems, 2019, 34(3): 2409-2418.

[40] ROLDAN G C, MINGUEZ R, GARCIA-BERTRAND R, et al. Robust transmission network expansion planning under correlated uncertainty [J]. IEEE Transactions on Power Systems, 2018, 34(3): 2071-2082.

[41] LI P, GUAN X, WU J, et al. Modeling dynamic spatial correlations of geographically distributed wind farms and constructing ellipsoidal uncertainty sets for optimization-based generation scheduling [J]. IEEE Transactions on Sustainable Energy, 2015, 6(4): 1594-1605.

[42] KUMAR P, YILDIRIM E A. Minimum-volume enclosing ellipsoids and core sets[J]. Journal of Optimization Theory and Applications, 2005, 126(1): 1-21.

[43] DING T, LV J, BO R, et al. Lift-and-project MVEE based convex hull for robust SCED with wind power integration using historical data-driven modeling approach [J]. Renewable



(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

Energy, 2016, 92: 415-427.

[44] ZHANG Y, AI X, WEN J, et al. Data-adaptive robust optimization method for the economic dispatch of active distribution networks[J]. IEEE Transactions on Smart Grid, 2018, 10(4): 3791-3800.

[45] VELLOSO A, STREET A, POZO D, et al. Two-stage robust unit commitment for co-optimized electricity markets: an adaptive data-driven approach for scenario-based uncertainty sets [J]. IEEE Transactions on Sustainable Energy, 2020, 11(2): 958-969.

[46] MANCILLA-DAVID F, ANGULO A, STREET A. Power management in active distribution systems penetrated by photovoltaic inverters: a data-driven robust approach[J]. IEEE Transactions on Smart Grid, 2020, 11(3): 2271-2280.

[47] WEI W, LIU F, MEI S. Distributionally robust co-optimization of energy and reserve dispatch [J]. IEEE Transactions on Sustainable Energy, 2015, 7(1): 289-300.

[48] LU X, CHAN K, XIA S, et al. Security-constrained multiperiod economic dispatch with renewable energy utilizing distributionally robust optimization[J]. IEEE Transactions on Sustainable Energy, 2018, 10(2): 768-779.

[49] XIONG P, JIRUTITIJAROEN P, SINGH C. A distributionally robust optimization model for unit commitment considering uncertain wind power generation [J]. IEEE Transactions on Power Systems, 2016, 32(1): 39-49.

[50] ZHAO C, JIANG R. Distributionally robust contingency-constrained unit commitment[J]. IEEE Transactions on Power Systems, 2017, 33(1): 94-102.

[51] 周安平,杨明,翟鹤峰,等.计及风电功率矩不确定性的分布鲁棒实时调度方法[J].中国电机工程学报,2018,38(20):5937-5946.
ZHOU Anping, YANG Ming, ZHAI Hefeng, et al. Distributionally robust real-time dispatch considering moment uncertainty of wind generation[J]. Proceedings of the CSEE, 2018, 38(20): 5937-5946.

[52] YANG Y, WU W. A distributionally robust optimization model for real-time power dispatch in distribution networks[J]. IEEE Transactions on Smart Grid, 2018, 10(4): 3743-3752.

[53] QIU H, GU W, XU Y, et al. Multi-time-scale rolling optimal dispatch for AC/DC hybrid microgrids with day-ahead distributionally robust scheduling [J]. IEEE Transactions on Sustainable Energy, 2018, 10(4): 1653-1663.

[54] BABAEI S, ZHAO C, FAN L. A data-driven model of virtual power plants in day-ahead unit commitment [J]. IEEE Transactions on Power Systems, 2019, 34(6): 5125-5135.

[55] HE C, ZHANG X, LIU T, et al. Distributionally robust scheduling of integrated gas-electricity systems with demand response[J]. IEEE Transactions on Power Systems, 2019, 34(5): 3791-3803.

[56] ZHANG Y, SHEN S, MATHIEU J L. Distributionally robust chance-constrained optimal power flow with uncertain renewables and uncertain reserves provided by loads[J]. IEEE Transactions on Power Systems, 2016, 32(2): 1378-1388.

[57] ZARE A, CHUNG C Y, ZHAN J, et al. A distributionally robust chance-constrained MILP model for multistage distribution system planning with uncertain renewables and loads [J]. IEEE Transactions on Power Systems, 2018, 33(5): 5248-5262.

[58] SHI Z, LIANG H, HUANG S, et al. Distributionally robust chance-constrained energy management for islanded microgrids [J]. IEEE Transactions on Smart Grid, 2018, 10(2): 2234-2244.

[59] GAO R, KLEYWEGT A J. Distributionally robust stochastic optimization with Wasserstein distance [EB/OL]. [2020-06-01]. https://arxiv.org/abs/1604.02199.

[60] BAYRAKSAN G, LOVE D K. Data-driven stochastic programming using phi-divergences [EB/OL]. [2020-06-01]. http://pdfs.semanticscholar.org/d820/7d08721649b82ba6d7df51ddac27ae20c7a3.pdf.

[61] ZHAO C, GUAN Y. Data-driven stochastic unit commitment for integrating wind generation [J]. IEEE Transactions on Power Systems, 2015, 31(4): 2587-2596.

[62] BAGHERI A, ZHAO C, GUO Y. Data-driven chance-constrained stochastic unit commitment under wind power uncertainty [C]// IEEE Power & Energy Society General Meeting, July 16-20, 2017, Chicago, USA.

[63] SHI Z, LIANG H, DINAVAHI V. Data-driven distributionally robust chance-constrained unit commitment with uncertain wind power[J]. IEEE Access, 2019, 7: 135087-135098.

[64] 阮贺彬,高红均,刘俊勇,等.考虑DG无功支撑和开关重构的主动配电网分布鲁棒无功优化模型[J].中国电机工程学报,2019,39(3):59-69.
RUAN Hebin, GAO Hongjun, LIU Junyong, et al. A distributionally robust reactive power optimization model for active distribution network considering reactive power support of DG and switch reconfiguration[J]. Proceedings of the CSEE, 2019, 39(3): 59-69.

[65] 税月,刘俊勇,高红均,等.考虑风电不确定性的电气能源系统两阶段分布鲁棒协同调度[J].电力系统自动化,2018,42(13):49-56.
SHUI Yue, LIU Junyong, GAO Hongjun, et al. A distributionally robust coordinated dispatch model for integrated electricity and heating systems considering uncertainty of wind power [J]. Automation of Electric Power Systems, 2018, 42(13): 49-56.

[66] DING T, YANG Q, YANG Y, et al. A data-driven stochastic reactive power optimization considering uncertainties in active distribution networks and decomposition method[J]. IEEE Transactions on Smart Grid, 2017, 9(5): 4994-5004.

[67] DING T, YANG Q, LIU X, et al. Duality-free decomposition based data-driven stochastic security-constrained unit commitment [J]. IEEE Transactions on Sustainable Energy, 2018, 10(1): 82-93.

[68] BAGHERI A, WANG J, ZHAO C. Data-driven stochastic transmission expansion planning [J]. IEEE Transactions on



(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

Power Systems, 2016, 32(5): 3461-3470.
[69] CHEN Y, GUO Q, SUN H, et al. A distributionally robust optimization model for unit commitment based on Kullback-Leibler divergence[J]. IEEE Transactions on Power Systems, 2018, 33(5): 5147-5160.
[70] LI Z, WU W, ZHANG B, et al. Kullback-Leibler divergence-based distributionally robust optimization model for heat pump day-ahead operational schedule to improve PV integration[J]. IET Generation, Transmission & Distribution, 2018, 12(13): 3136-3144.
[71] CAO Y, WEI W, WANG J, et al. Capacity planning of energy hub in multi-carrier energy networks: a data-driven robust stochastic programming approach [J]. IEEE Transactions on Sustainable Energy, 2018, 11(1): 3-14.
[72] ZHANG H, HU Z, MUNSING E, et al. Data-driven chance-constrained regulation capacity offering for distributed energy resources [J]. IEEE Transactions on Smart Grid, 2018, 10(3): 2713-2725.
[73] ZHAO C, GUAN Y. Data-driven risk-averse two-stage stochastic program with ζ-structure probability metrics[EB/OL]. [2020-06-01]. http://www.optimization-online.org/DB_FILE/2015/07/5014.pdf.
[74] GUO Y, BAKER K, DALL'ANESE E, et al. Data-based distributionally robust stochastic optimal power flow: Part Ⅰ methodologies [J]. IEEE Transactions on Power Systems, 2018, 34(2): 1483-1492.
[75] DUAN C, FANG W, JIANG L, et al. Distributionally robust chance-constrained approximate AC-OPF with Wasserstein metric [J]. IEEE Transactions on Power Systems, 2018, 33(5): 4924-4936.
[76] WANG C, GAO R, WEI W, et al. Risk-based distributionally robust optimal gas-power flow with Wasserstein distance [J]. IEEE Transactions on Power Systems, 2018, 34(3): 2190-2204.
[77] YAO L, WANG X, DUAN C, et al. Data-driven distributionally robust reserve and energy scheduling over Wasserstein balls [J]. IET Generation, Transmission & Distribution, 2017, 12(1): 178-189.
[78] ORDOUDIS C, NGUYEN V A, KUHN D, et al. Energy and reserve dispatch with distributionally robust joint chance constraints[EB/OL]. [2020-06-01]. http://www.optimization-online.org/DB_FILE/2018/12/6962.pdf.
[79] ZHU R, WEI H, BAI X. Wasserstein metric based distributionally robust approximate framework for unit commitment [J]. IEEE Transactions on Power Systems, 2019, 34(4): 2991-3001.
[80] XU X, YAN Z, SHAHIDEHPOUR M, et al. Data-driven risk-averse two-stage optimal stochastic scheduling of energy and reserve with correlated wind power[J]. IEEE Transactions on Sustainable Energy, 2019, 11(1): 436-447.
[81] WANG C, GAO R, QIU F, et al. Risk-based distributionally robust optimal power flow with dynamic line rating[J]. IEEE Transactions on Power Systems, 2018, 33(6): 6074-6086.
[82] 王晗,严正,徐潇源,等.基于稀疏多项式混沌展开的孤岛微电网全局灵敏度分析[J].电力系统自动化,2019,43(10):64-77.
WANG Han, YAN Zheng, XU Xiaoyuan, et al. Global sensitivity analysis for islanded microgrid based on sparse polynomial chaos expansion[J]. Automation of Electric Power Systems, 2019, 43(10): 64-77.
[83] WANG H, YAN Z, SHAHIDEHPOUR M, et al. Optimal energy storage allocation for mitigating the unbalance in active distribution network via uncertainty quantification [J/OL]. IEEE Transactions on Sustainable Energy [2020-05-06]. https://ieeexplore.ieee.org/document/9088223.
[84] WANG H, YAN Z, SHAHIDEHPOUR M, et al. Quantitative evaluations of uncertainties in multivariate operations of microgrids [J]. IEEE Transactions on Smart Grid, 2020, 11(4): 2892-2903.
[85] WANG H, YAN Z, XU X, et al. Probabilistic power flow analysis of microgrid with renewable energy [J]. International Journal of Electrical Power & Energy Systems, 2020, 114: 105393.
[86] CHENG J, CHEN R, NAJM N H, et al. Distributionally robust optimization with principal component analysis [J]. SIAM Journal on Optimization, 2018, 28(2): 1817-1841.
[87] FU X, GUO Q, SUN H. Statistical machine learning model for stochastic optimal planning of distribution networks considering a dynamic correlation and dimension reduction[J]. IEEE Transactions on Smart Grid, 2020, 11(4): 2904-2917.
[88] 刘全,翟建伟,章宗长,等.深度强化学习综述[J].计算机学报,2018,41(1):1-27.
LIU Quan, ZHAI Jianwei, ZHANG Zongchang, et al. A survey on deep reinforcement learning[J]. Chinese Journal of Computers, 2018, 41(1): 1-27.
[89] AL-SAFFAR M, MUSILEK P. Reinforcement learning based distributed BESS management for mitigating overvoltage issues in systems with high PV penetration[J]. IEEE Transactions on Smart Grid, 2020, 11(4): 2980-2994.
[90] YAN Z, XU Y. Data-driven load frequency control for stochastic power systems: a deep reinforcement learning method with continuous action search[J]. IEEE Transactions on Power Systems, 2018, 34(2): 1653-1656.

鲁卓欣(1995—),女,博士研究生,主要研究方向:电力系统随机优化。E-mail:Zhuoxin_Lu@sjtu.edu.cn

徐潇源(1989—),男,通信作者,助理教授,主要研究方向:电力系统不确定性分析、电力系统优化运行。E-mail:xuxiaoyuan@sjtu.edu.cn

严　正(1964—),男,教授,博士生导师,主要研究方向:电力系统优化运行、电力系统稳定分析及智能电网。E-mail:yanz@sjtu.edu.cn

(编辑　鲁尔姣)



(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

## Overview on Data-driven Optimal Scheduling Methods of Power System in Uncertain Environment

*LU Zhuoxin*[1], *XU Xiaoyuan*[1], *YAN Zheng*[1], *WU Jiang*[2], *SANG Da*[2], *WANG Shu*[2]

(1. Key Laboratory of Control of Power Transmission and Conversion, Ministry of Education (Shanghai Jiao Tong University), Shanghai 200240, China;
2. East China Branch of State Grid Corporation of China, Shanghai 200120, China)

**Abstract:** With the large-scale integration of renewable energy, uncertainties significantly rise in power system operation. Scheduling methods that take uncertainties into account gradually draw more and more attentions. Meanwhile, the establishment of an accurate uncertain model is the premise and key to solve the optimization problem. The output of the renewable energy has complex uncertainties, and its power generation data provide scientific data support for stochastic scheduling. This paper summarizes the theoretical methods and application scenarios of data-driven scheduling for power systems in uncertain environments. Firstly, data-driven modeling methods of random variables in traditional stochastic optimal scheduling are summarized. Secondly, modeling methods of data-driven uncertain sets in robust optimal scheduling are introduced. Then, aiming at the problems of inaccurate modeling of uncertain factors and conservative results of the robust optimization in stochastic optimization, the theory and method of optimal scheduling for power systems are explained based on data-driven distributed robustness; and the construction method of probability distribution fuzzy set of random variables, the model construction and solution algorithm of distribution robust optimization are sorted out. Finally, the future research work of data-driven scheduling for power systems is prospected.

This work is supported by National Natural Science Foundation of China (No. 51707115).

**Key words:** power system; data-driven; stochastic optimization; robust optimization; distributionally robust optimization; renewable energy





(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net